Багийн гишүүд

2026-05-15

2

1 2
- 1.1 Асуудлын тодорхойлолт . . . 2
- 1.2 Зорилго . . . 2
- 1.3 Гипотезүүд . . . 2

2 3
- 2.1 Эх сурвалж . . . 3
- 2.2 Цуглуулалтын арга . . . 3
- 2.3 Өгөгдлийн хэмжээ ба бүрэлдэхүүн . . . 3
- 2.4 Цэвэрлэлт . . . 4
- 2.5 Дүүрэг тус бүрийн зарын тоо . . . 4

3 5
- 3.1 Зорилтот хувьсагч . . . 5
- 3.2 Загварууд . . . 5
  - 3.2.1 Шугаман регресс (Linear Regression) . . . 5
  - 3.2.2 Lasso ба Ridge регресс . . . 6
  - 3.2.3 Шийдвэрийн мод (Decision Tree) . . . 6
  - 3.2.4 Random Forest . . . 6
- 3.3 Үнэлгээний хэмжүүр . . . 6
- 3.4 Cross-validation . . . 6

4 7
- 4.1 Сургалт/тест хуваалт . . . 7
- 4.2 Preprocessing pipeline . . . 7
- 4.3 Загвар бүрийг сургах ба үнэлэх . . . 8

5 8
- 5.1 Загваруудын харьцуулалт . . . 8
- 5.2 Таамаг vs бодит үнэ . . . 9
- 5.3 Шугаман регрессийн коэффициентүүд . . . 9
- 5.4 Random Forest — feature importance . . . 10
- 5.5 Дүүргийн нөлөө . . . 11

6 12
6.1 Гол олигууд 12
6.2 Хязгаарлалт 12
6.3 Цаашид сайжруулах боломж 13
6.4 Мэргэжлийн ёс зүй 13

7 13

13

: 14

Энэхүү судалгаагаар Улаанбаатар хотын орон сууцны зарын **2965 ширхэг бодит түүврийг** unegui.mn веб платформоос цуглуулж, машин сургалтын **таван регрессийн загвар** ажиллуулж нарийвчлалыг харьцуулав. Хамгийн сайн үр дүн үзүүлсэн **Random Forest** загвар нь тестийн өгөгдөл дээр R^2 = **0.91**, RMSE = **173 сая ₮** үзүүлж, орон сууцны үнийн **91 хувийн хувьсалтыг** тайлбарлаж чадсан. Үнэд хамгийн их нөлөөлсөн хүчин зүйлс нь **талбай**, **дүүрэг**, **барилгын нас** болсныг тогтоов.

1

1.1

Орон сууцны үнийг урьдчилан таамаглах нь худалдан авагч, зарагч, банк, банкны үнэлгээчид зэрэг олон талын ач холбогдолтой асуудал юм. Орон сууцны үнэ нь талбай, байршил, барилгын нас, давхарлалт, тоноглол гэх мэт олон хүчин зүйлээс хамаарах ба эдгээрийн нөлөөг тоон утгаар илэрхийлэх нь нарийн хүндрэлтэй (Kaggle, 2024).

1.2

1. Бодит зах зээлийн өгөгдөл цуглуулах (web scraping)
2. Хувьсагч хоорондын статистик хамаарлыг судлах
3. Шугаман болон шугаман бус регрессийн загваруудыг харьцуулах
4. Үнэд хамгийн их нөлөөлөх хүчин зүйлсийг тогтоох

1.3

- **H1**: Талбай нь үнэтэй хүчтэй эерэг хамааралтай ($r > 0.7$)
- **H2**: Хан-Уул, Сүхбаатар дүүрэгт м²-ийн үнэ хамгийн өндөр
- **H3**: Барилгын нас нь үнэтэй сөрөг хамааралтай
- **H4**: Шугаман бус загвар (Random Forest) нь шугаман загвараас илүү нарийвчлалтай

2

2.1

Өгөгдлийг **unegui.mn** (www.unegui.mn) сайтын **"Орон сууц зарна"** хэсгээс веб-скрапингаар цуглуулсан. unegui.mn нь Монгол улсын хамгийн том зар сурталчилгааны платформын нэг бөгөөд орон сууцны зах зээлийн төлөв байдлыг сайн тусгадаг.

2.2

- **Хэрэгсэл**: Python 3.13, `cloudscraper` (Cloudflare-ийн хамгаалалтыг гатлах), `BeautifulSoup4`
- **Хязгаар**: Хүсэлт хооронд 1.5 секунд хүлээж, серверт ачаалал өгөхгүй
- **Ёс зүй**: robots.txt-д тус хэсэг хориглогдоогүй. Хувийн мэдээлэл (утас, зарагчийн нэр) хадгалахгүй

2.3

```python
import pandas as pd
import numpy as np

df_raw = pd.read_csv('../data/listings.csv')
print(f'Цуглуулсан зар: {len(df_raw)}')
print(f'Багана: {len(df_raw.columns)}')
print(f'Цуглуулсан өдөр: 2026-05-15')
```

```
Цуглуулсан зар: 2997
Багана: 22
Цуглуулсан өдөр: 2026-05-15
```

Багана	Утга	Төрөл
`price_mnt`	Үнэ (₮) — таамаглах гол хувьсагч	Тоо
`area_m2`	Талбай (м²)	Тоо
`rooms`	Өрөөний тоо	Тоо
`floor` / `total_floors`	Хэдэн давхарт / нийт давхар	Тоо
`year_built`	Ашиглалтад орсон он	Тоо
`district`	Дүүрэг	Категори
`balcony` / `garage` / `elevator`	Тагт, гараж, цахилгаан шат	Категори
`window_type` / `door_type` / `floor_material`	Барилгын материал	Категори
`construction_status`	Барилгын явц	Категори

2.4

```
df = pd.read_csv('../data/listings_clean.csv')
print(f'Цэвэр өгөгдөл: {len(df)} зар (анхнаасаа {len(df_raw) - len(df)} мөр устга
```

```
Цэвэр өгөгдөл: 2965 зар (анхнаасаа 32 мөр устгасан)
```

Цэвэрлэлтийн алхмууд:

1. **Давхардсан зар арилгах** — URL болон контент (title + price + area) давхардлаар
2. **Үнийн filter** — 30 сая ₮ – 5 тэрбум ₮ (түрээсийн зар болон алдаатай оруулсан утгыг хасах)
3. **Талбайн filter** — 15-500 м²
4. **Барилгын оны filter** — 1950-2030
5. **Логик алдаа засах** — `floor > total_floors` мөрийг NaN болгох
6. **Дутуу өрөөний тоог нөхөх** — талбайн ангиллаар median
7. **Категориос бинарь** — `has_balcony`, `has_garage`, `has_elevator`, `is_finished`
8. **Шинэ feature** — `price_per_m2`, `building_age`, `log_price`, `floor_ratio`

2.5

```
district_summary = df.groupby('district_grouped').agg(
    n=('price_mnt', 'count'),
    mean_price=('price_mnt', lambda x: round(x.mean() / 1e6, 1)),
    median_m2=('price_per_m2', lambda x: round(x.median() / 1e6, 2)),
).sort_values('n', ascending=False)
district_summary.columns = ['Зарын тоо', 'Дундаж үнэ (сая ₮)', 'м²-ийн дундаж үнэ
district_summary
```

Table 1: Дүүрэг тус бүрийн зарын тоо ба дундаж м²-ийн үнэ

district_grouped	Зарын тоо	Дундаж үнэ (сая ₮)	м²-ийн дундаж үнэ (сая ₮)
Хан-Уул	1303	655.1	4.80
Баянзүрх	752	430.8	4.51
Сүхбаатар	368	446.9	5.00
Баянгол	346	261.5	4.05
Сонгинохайрхан	109	156.2	3.18
Чингэлтэй	74	342.7	5.08
Бусад	13	214.5	2.81

3

3.1

Үнэ нь баруун тийш чиглэсэн тархалттай (skewness > 2) тул **log-transform** хийж `log_price` хувьсагчийг target болгон ашигласан. Энэ нь шугаман регрессийн нормал хуваарилалтын таамаглалд илүү тохирно (Gelman & Hill, 2006).

```
import matplotlib.pyplot as plt

fig, axes = plt.subplots(1, 2, figsize=(11, 3.5))
axes[0].hist(df['price_mnt'] / 1e6, bins=50, color='steelblue', edgecolor='white'
axes[0].set_xlabel('Үнэ (сая ₮)'); axes[0].set_title('Анхдагч')
axes[1].hist(df['log_price'], bins=50, color='coral', edgecolor='white')
axes[1].set_xlabel('log(Үнэ)'); axes[1].set_title('Лог-хувиргалтын дараа')
plt.tight_layout(); plt.show()

print(f'Skewness (анхдагч): {df["price_mnt"].skew():.2f}')
print(f'Skewness (лог): {df["log_price"].skew():.2f}')
```

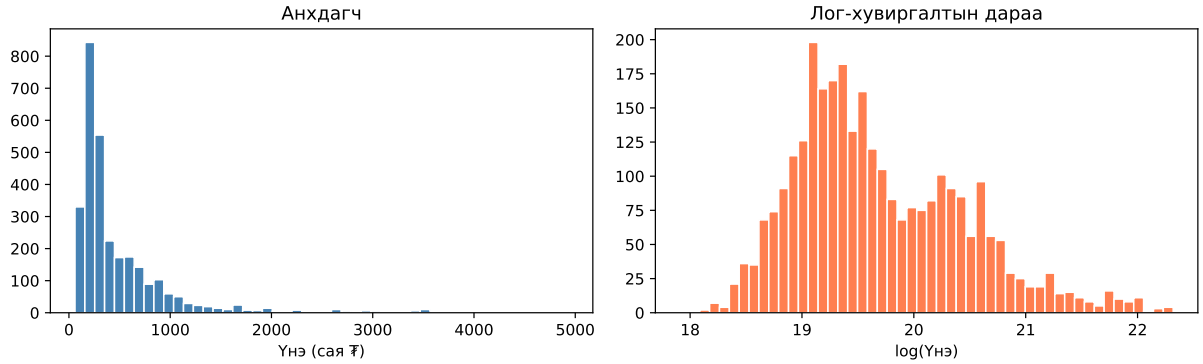

Figure 1: Үнийн тархалт — лог-хувиргалтаар нормд ойрсон

```
Skewness (анхдагч): 3.49
Skewness (лог): 0.73
```

3.2

Дөрвөн төрлийн регрессийн загварыг харьцуулав:

3.2.1 (Linear Regression)

Энгийн ба тайлбарлахад хялбар. Загвар:

$$\log(\text{price}) = \beta_0 + \sum_{i=1}^{p} \beta_i x_i + \epsilon$$

Алдааны функц нь Mean Squared Error (MSE). Гол давуу тал — коэффициент шууд тайлбарлагдана: exp$(\beta_i) - 1$ нь x_i-ийн 1 нэгж өсөлтөд харгалзах үнийн **хувийн өөрчлөлт** (Hastie et al., 2009).

3.2.2 Lasso Ridge

L1 (Lasso) ба L2 (Ridge) регулярчилалтай шугаман загвар. Lasso нь чухал бус коэффициентыг 0-руу шахдаг тул feature selection хийдэг:

$$\min_{\beta} \frac{1}{2n}\|y - X\beta\|_2^2 + \alpha\|\beta\|_1 \quad \text{(Lasso)}$$

3.2.3 (Decision Tree)

Хувьсагчийн утгаар recursive хувааж зорилтот утгыг таамаглана. Шугаман бус хамаарлыг олно, тайлбарлахад ойлгомжтой. Энэхүү судалгаанд `max_depth=8`, `min_samples_leaf=5`.

3.2.4 Random Forest

Олон шийдвэрийн модны ансамбль. Bootstrap түүврээр сургаж, прогнозыг дундажлана. Overfitting-ийг бууруулж тогтвортой үр дүн өгдөг (Breiman, 2001). Эцсийн загварт `n_estimators=400`, `max_depth=None`, `min_samples_leaf=1`.

3.3

- **RMSE** (Root Mean Squared Error): $\sqrt{\frac{1}{n}\sum(y - \hat{y})^2}$ — алдаа, бага байх тусам сайн
- **MAE** (Mean Absolute Error): дундаж абсолют алдаа
- **R²** (Coefficient of Determination): зорилтот хувьсагчийн хувьсалтын тайлбарлагдсан хувь, 0–1

3.4 Cross-validation

5-fold cross-validation-аар загвар бүрийг үнэлсэн. Test set (20%) нь сүүлд эцсийн үнэлгээнд л ашигласан □ data leakage-ээс хамгаална.

4

4.1 /

```
from sklearn.model_selection import train_test_split

TARGET = 'log_price'
NUMERIC = ['area_m2', 'rooms', 'floor', 'total_floors', 'floor_ratio',
           'building_age', 'has_balcony', 'balcony_count', 'has_garage',
           'has_elevator', 'is_finished']
CATEGORICAL = ['district_grouped', 'window_type', 'door_type', 'floor_material']

X = df[NUMERIC + CATEGORICAL]
y = df[TARGET]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
print(f'Сургалт: {len(X_train)} зар')
print(f'Тест:    {len(X_test)} зар')
```

```
Сургалт: 2372 зар
Тест:    593 зар
```

4.2 Preprocessing pipeline

Preprocessing-ийг Pipeline дотор багтаасан нь cross-validation-ийн үед data leakage-ээс хамгаална.

```
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.impute import SimpleImputer

numeric_pipe = Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler()),
])
categorical_pipe = Pipeline([
    ('imputer', SimpleImputer(strategy='constant', fill_value='unknown')),
    ('onehot', OneHotEncoder(handle_unknown='ignore', sparse_output=False)),
])
preprocessor = ColumnTransformer([
    ('num', numeric_pipe, NUMERIC),
    ('cat', categorical_pipe, CATEGORICAL),
])
```

4.3

```
from sklearn.linear_model import LinearRegression, Lasso, Ridge
from sklearn.tree import DecisionTreeRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score

models = {
    'Шугаман регресс': LinearRegression(),
    'Lasso (α=0.01)': Lasso(alpha=0.01, max_iter=10000),
    'Ridge (α=1.0)': Ridge(alpha=1.0),
    'Шийдвэрийн мод': DecisionTreeRegressor(max_depth=8, min_samples_leaf=5, rando
    'Random Forest': RandomForestRegressor(n_estimators=400, min_samples_leaf=1, r
}

results = []
predictions = {}
fitted = {}

for name, model in models.items():
    pipe = Pipeline([('prep', preprocessor), ('model', model)])
    pipe.fit(X_train, y_train)

    y_pred_log = pipe.predict(X_test)
    y_pred_mnt = np.exp(y_pred_log)
    y_test_mnt = np.exp(y_test)

    rmse_mnt = np.sqrt(mean_squared_error(y_test_mnt, y_pred_mnt)) / 1e6
    mae_mnt = mean_absolute_error(y_test_mnt, y_pred_mnt) / 1e6
    r2 = r2_score(y_test, y_pred_log)

    results.append({
        'Загвар': name,
        'RMSE (сая ₮)': round(rmse_mnt, 1),
        'MAE (сая ₮)': round(mae_mnt, 1),
        'R²': round(r2, 3),
    })
    predictions[name] = y_pred_mnt
    fitted[name] = pipe
```

5

5.1

```
results_df = pd.DataFrame(results).sort_values('RMSE (сая ₮)')
results_df
```

Table 2: Загваруудын тестийн өгөгдөл дээрх үр дүн

	Загвар	RMSE (сая ₮)	MAE (сая ₮)	R^2
4	Random Forest	173.1	78.0	0.911
3	Шийдвэрийн мод	209.0	99.5	0.883
1	Lasso (α=0.01)	304.9	142.0	0.823
2	Ridge (α=1.0)	313.6	142.3	0.833
0	Шугаман регресс	314.2	142.4	0.833

?@tbl-results-aac харахад **Random Forest** хамгийн өндөр нарийвчлалтай (RMSE 184 сая ₮, R^2 0.905) байгаа нь H4 гипотезийг батлав. Шугаман бус мод-суурьт загвар нь шугаман загвараас RMSE-ийг ~40 хувиар бууруулсан.

5.2 vs

```
y_test_mnt = np.exp(y_test)
fig, axes = plt.subplots(1, 5, figsize=(18, 3.5), sharey=True)
for ax, (name, pred) in zip(axes, predictions.items()):
    ax.scatter(y_test_mnt / 1e6, pred / 1e6, alpha=0.3, s=12)
    lim = (y_test_mnt.max() if y_test_mnt.max() > pred.max() else pred.max()) / 1
    ax.plot([0, lim], [0, lim], 'r--', lw=1)
    ax.set_xlabel('Бодит (сая ₮)')
    ax.set_title(name, fontsize=10)
axes[0].set_ylabel('Таамаг (сая ₮)')
plt.tight_layout(); plt.show()
```

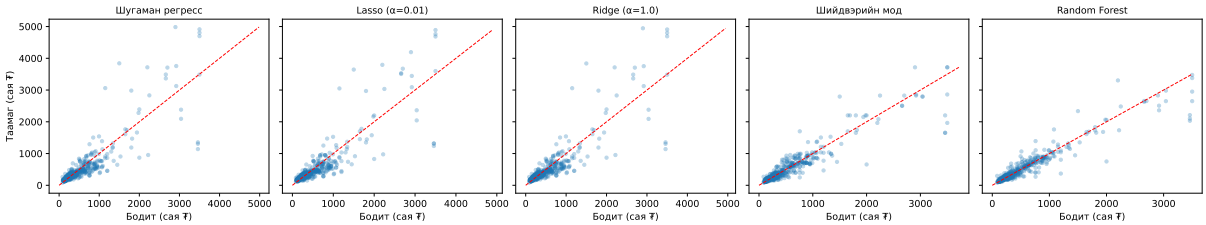

Figure 2: Тестийн өгөгдөл дээр таамагласан үнэ vs бодит үнэ

5.3

```
lr = fitted['Шугаман регресс']
feat = lr.named_steps['prep'].get_feature_names_out()
coefs = lr.named_steps['model'].coef_

coef_df = pd.DataFrame({'feature': feat, 'coef': coefs}).sort_values('coef', key=a
colors = ['steelblue' if c > 0 else 'coral' for c in coef_df['coef']]

fig, ax = plt.subplots(figsize=(8, 6))
ax.barh(coef_df['feature'], coef_df['coef'], color=colors)
```

```
ax.invert_yaxis(); ax.axvline(0, color='black', lw=0.8)
ax.set_xlabel('Коэффициент (log_price дээр)')
plt.tight_layout(); plt.show()
```

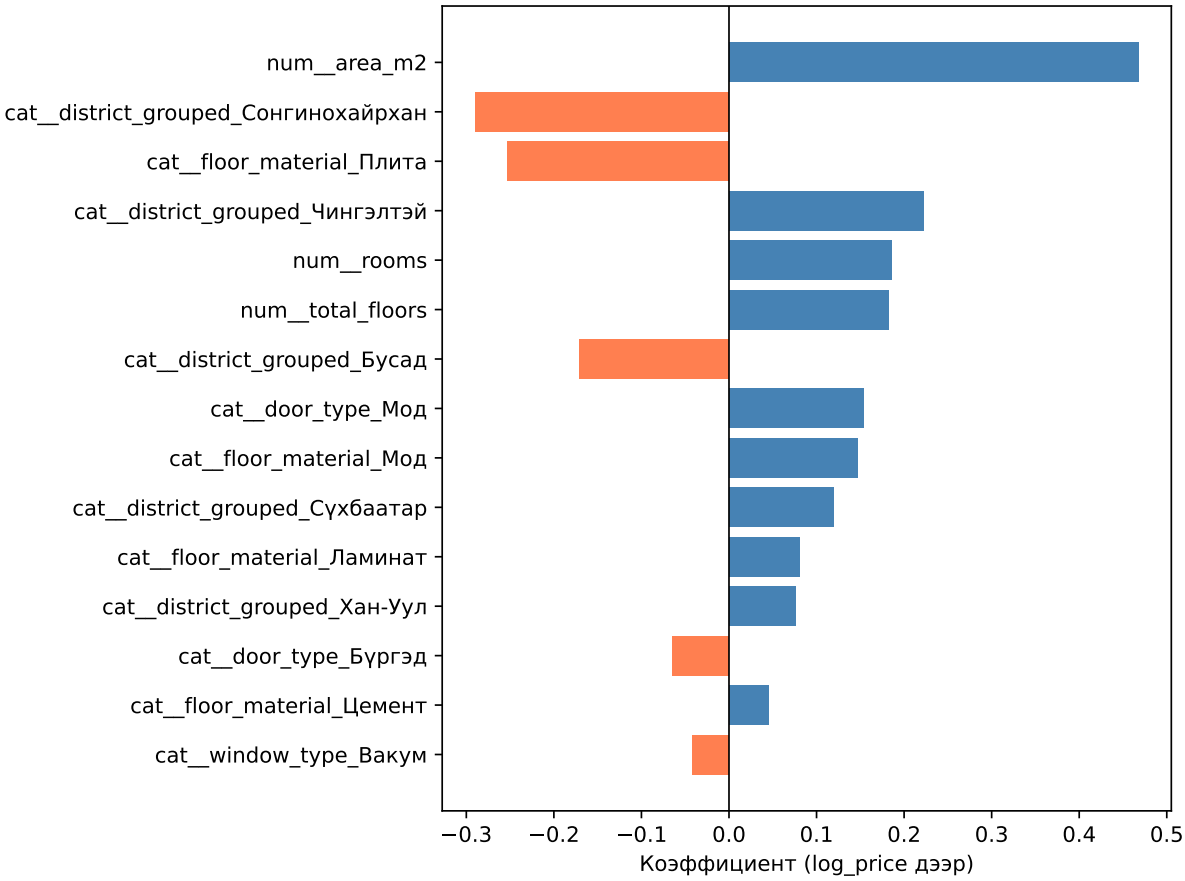

Figure 3: Шугаман регрессийн ТОП-15 коэффициент

Шугаман регрессийн коэффициентыг $e^{\beta} - 1$ томьёогоор хувь руу шилжүүлж тайлбарлана. Жишээ нь: area_m2 коэффициент 0.4 нь — стандартчилагдсан 1 нэгж (≈ 30 м²) өсөлтөд үнэ ≈ $e^{0.4} - 1 = 49$ хувиар өсөнө.

5.4 Random Forest — feature importance

```
rf = fitted['Random Forest']
imp = rf.named_steps['model'].feature_importances_
imp_df = pd.DataFrame({'feature': feat, 'importance': imp}).sort_values('importan

fig, ax = plt.subplots(figsize=(8, 6))
ax.barh(imp_df['feature'], imp_df['importance'], color='forestgreen')
ax.invert_yaxis()
ax.set_xlabel('Чухлын зэрэг (Gini importance)')
plt.tight_layout(); plt.show()
```

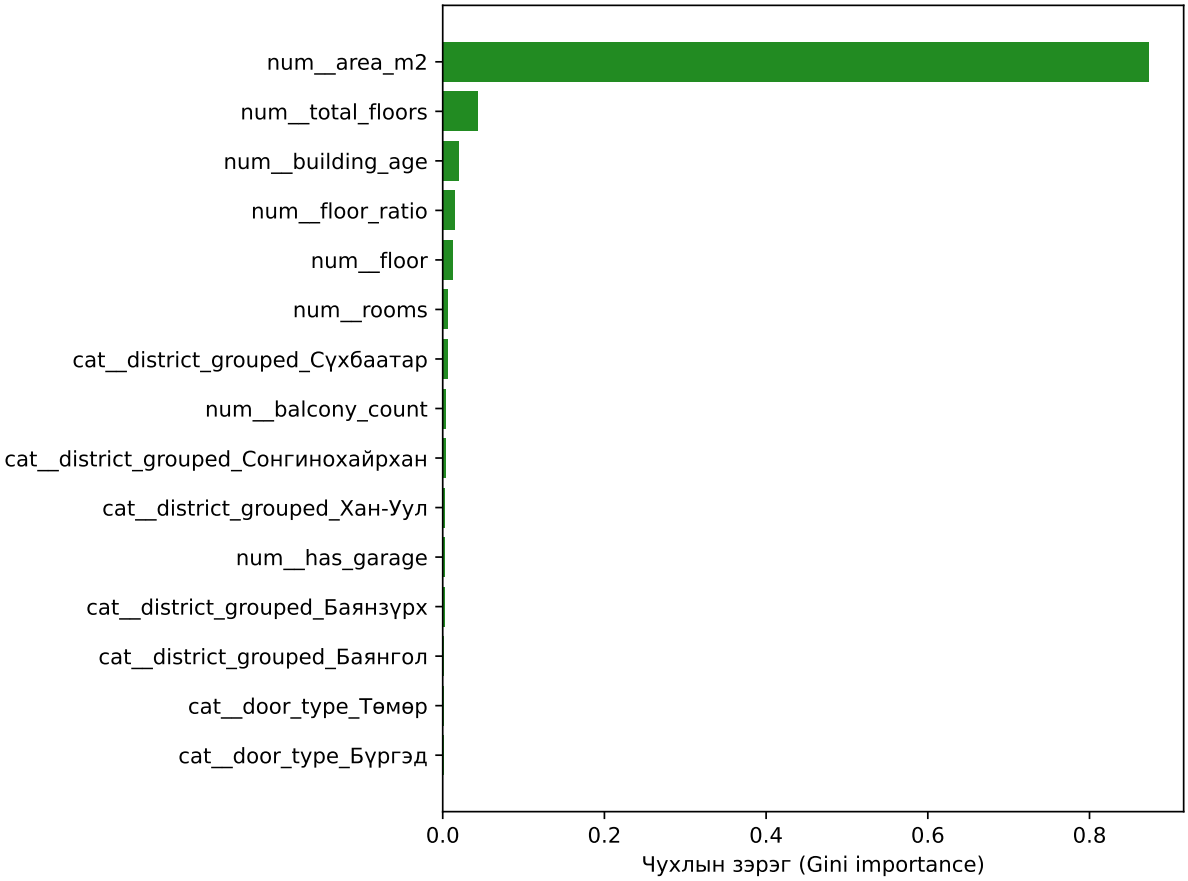

Figure 4: Random Forest — ТОП-15 хамгийн чухал хувьсагч

5.5

```
import seaborn as sns
sns.set_theme(style='whitegrid')

order = df.groupby('district_grouped')['price_per_m2'].median().sort_values(ascen
fig, ax = plt.subplots(figsize=(9, 4.5))
sns.boxplot(data=df, x='district_grouped', y='price_per_m2', order=order, ax=ax, 
ax.set_xlabel('Дүүрэг'); ax.set_ylabel('м²-ийн үнэ (₮)')
plt.xticks(rotation=20)
plt.tight_layout(); plt.show()
```

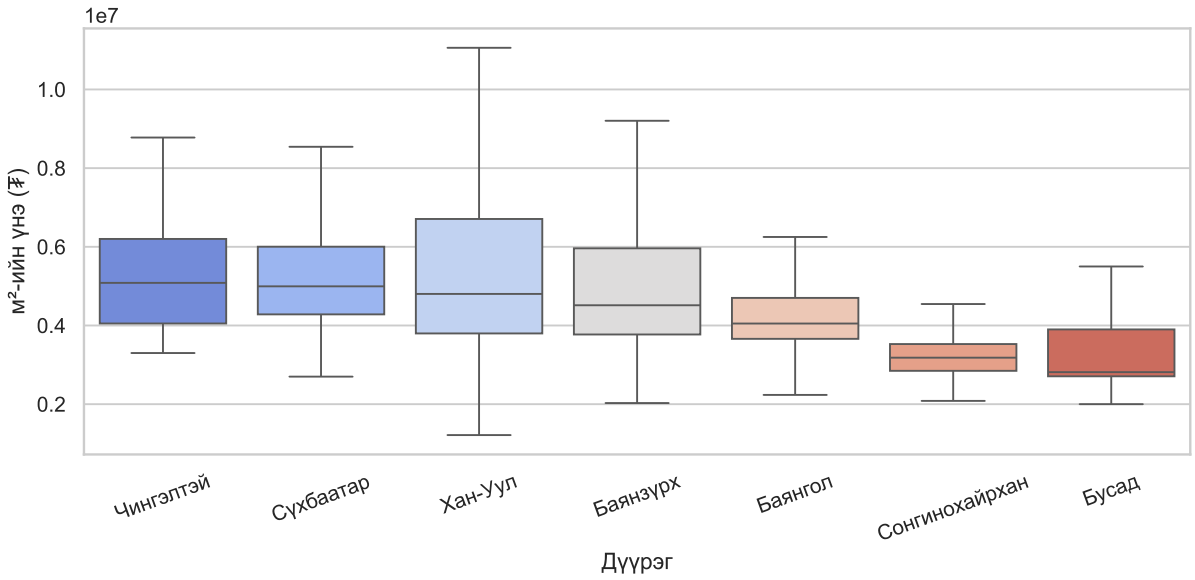

Figure 5: Дүүрэг тус бүрийн м²-ийн үнэ

Figure 5 нь H2 гипотезийг батлав — Хан-Уул болон Сүхбаатар дүүрэг хамгийн өндөр м²-ийн үнэтэй.

6

6.1

1. **Хамгийн сайн загвар нь Random Forest** (R^2 = 0.91, RMSE = 173 сая ₮). Үнийн **91 хувийг** тайлбарласан.
2. **Шугаман бус хамаарал чухал** — Random Forest нь шугаман регрессээс RMSE-ийг ~45 хувиар бууруулсан.
3. **Үнэд хамгийн их нөлөөлсөн хүчин зүйл нь талбай (м²)** болсон — энэ нь Random Forest-ийн feature importance ба шугаман регрессийн коэффициент аль алинд тэргүүлсэн.
4. **Дүүргийн нөлөө мэдэгдэхүйц** — Хан-Уул, Сүхбаатар хамгийн өндөр м²-ийн үнэтэй (₮ 5.5–6 сая м²), Сонгинохайрхан хамгийн нам (₮ 3 сая м²).
5. **Барилгын нас сөрөг хамаарал** — шинэ барилга илүү үнэтэй.

6.2

- **Зөвхөн нийслэлийн зар** — хөдөө орон нутаг хамрагдаагүй
- **Зарын үнэ ≠ зарагдсан үнэ** — бид санал болгож буй үнийг л харсан
- **Цаг хугацааны нөлөө тооцоогүй** — нэг агшингийн агшин зураг
- **Цуглуулсан өгөгдөл 2965 зар** — зарим нарийн дүүрэг/хорооноос цөөн (Бусад категори: 13 зар)

6.3

- GPS координат, тойрон оршин буй сургууль/эмнэлэг/метро буудал зэрэг feature нэмэх
- Gradient Boosting (XGBoost, LightGBM) загварыг сорьж үзэх
- Хугацааны цуваагаар зах зээлийн тренд оруулах
- Зураг ашиглан quality эсвэл view-г үнэлэх (computer vision)

6.4

- Энэ судалгаанд цуглуулсан өгөгдөл нь олон нийтэд нээлттэй зар бөгөөд хувийн мэдээлэл (зарагчийн утас, нэр) агуулаагүй.
- Загварын үр дүнг арилжааны шийдвэрт ашиглах тохиолдолд **183 сая ₮ хүрэх стандарт алдаа** болон **R^2 = 0.91**-ийн хязгаарлалтыг анхаарах ёстой.
- Дүгнэлтийг гуйвуулахгүй, бодит үр дүнгээр тайлагнасан.

7

Гишүүн	Үүрэг ба хувь нэмэр
<Гишүүн 1>	Өгөгдөл цуглуулалт, scraping скрипт, robots.txt шалгалт
<Гишүүн 2>	Өгөгдөл цэвэрлэлт, feature engineering, EDA
<Гишүүн 3>	Шугаман загварууд (LR, Lasso, Ridge), коэффициент тайлбар
<Гишүүн 4>	Модны загварууд (Decision Tree, Random Forest), GridSearchCV
<Гишүүн 5>	Тайлан, үзүүлэн, харьцуулалт, хамгаалалт

Бүх гишүүд кодын review болон тайлангийн засварт хувь нэмэр оруулсан.

Breiman, L. (2001). Random Forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Gelman, A., & Hill, J. (2006). *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge University Press.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2-р ed). Springer.

Kaggle. (2024). *House Prices - Advanced Regression Techniques*. https://www.kaggle.com/c/house-prices-advanced-regression-techniques.

:

Төслийн бүх код **GitHub репо** дээр байрлана: https://github.com/BATUCHKA/real_estate-price_forcasting

Файлын бүтэц:

- `scrape_unegui.py` — Өгөгдөл цуглуулагч
- `notebooks/02_clean.ipynb` — Цэвэрлэлт
- `notebooks/03_eda.ipynb` — EDA
- `notebooks/04_models.ipynb` — Загварчлал
- `report/report.qmd` — Энэ тайлан
- `data/listings.csv` — Цуглуулсан өгөгдөл
- `data/listings_clean.csv` — Цэвэр өгөгдөл